Прикладной анализ данных в экономике и финансах

Лекция 6
Повторение тервера и матстата

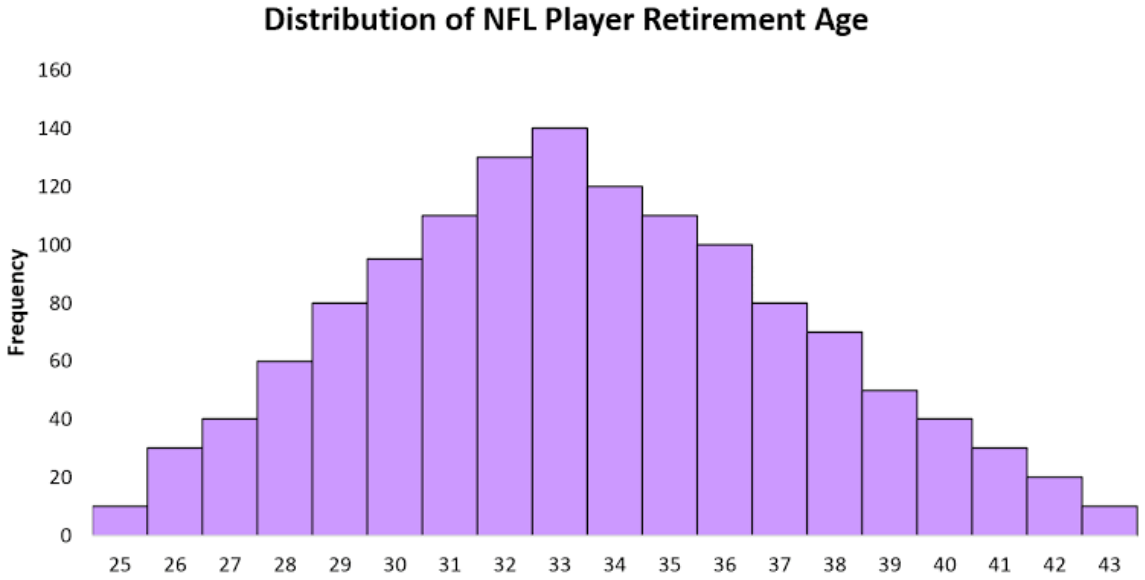
Цветкова Алёна

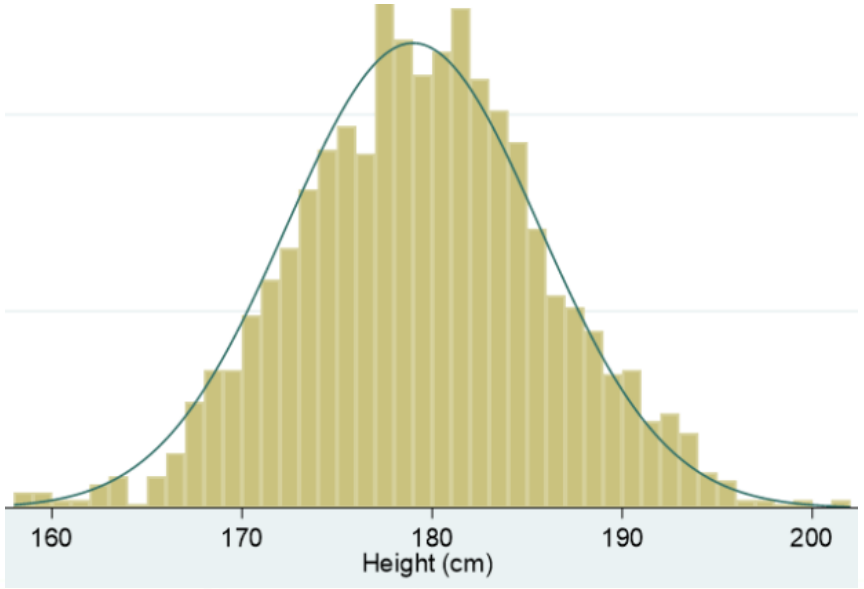
Департамент математики
ФЭН ВШЭ, весна 2027

$N(\mu,\sigma^2)$
Normal Distribution

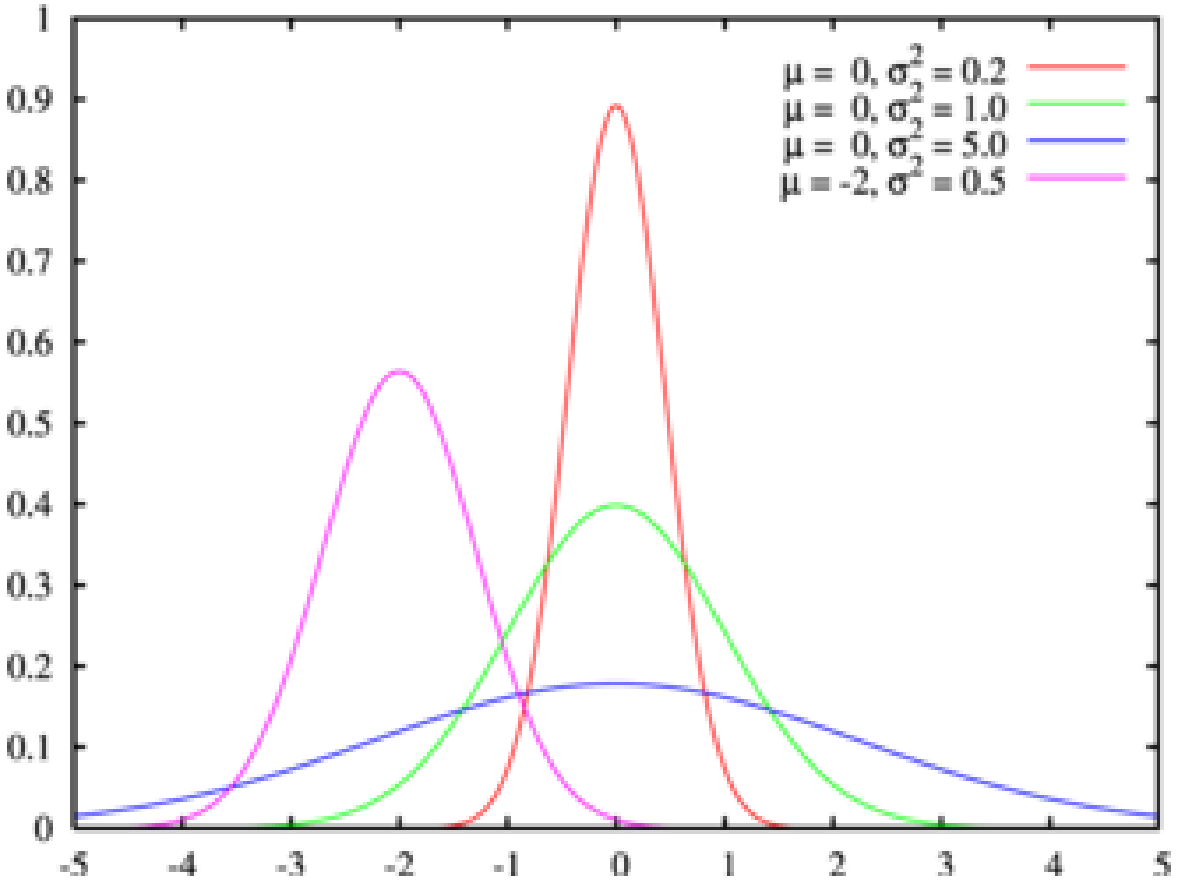
Где еще можно заметить?







Нормальное распределение

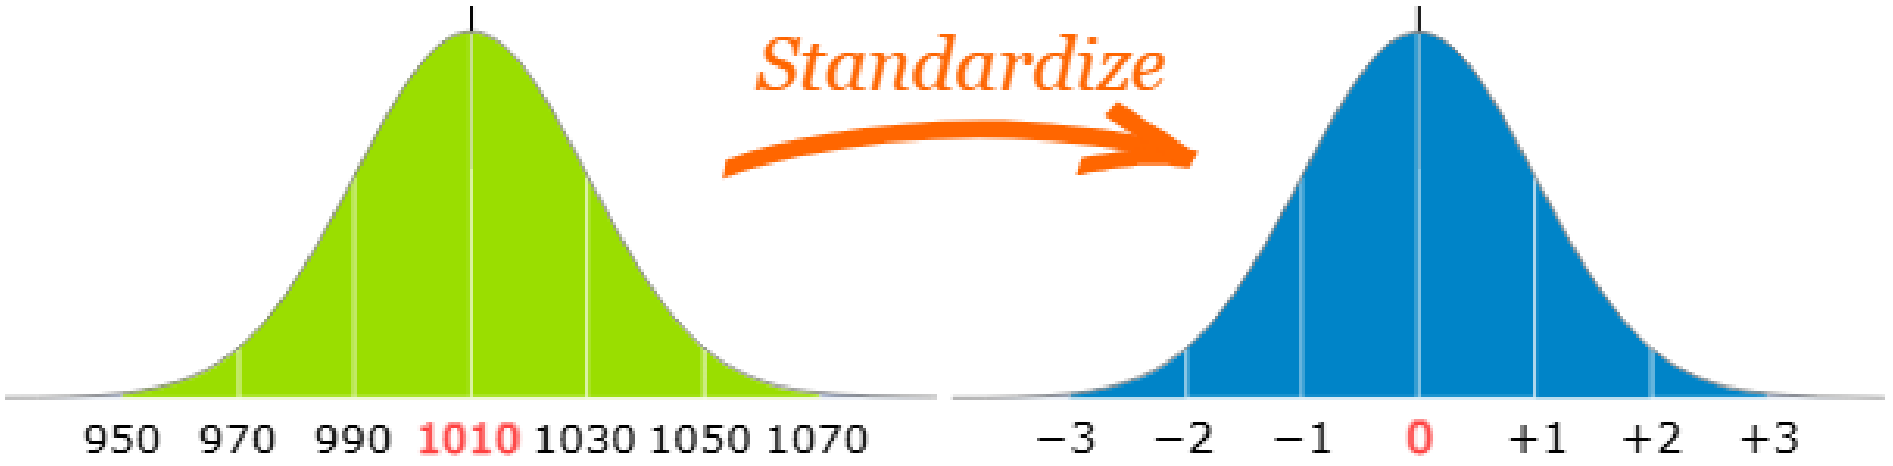


1738г Муавр - «Доктрина случайностей»

1809г Гаусс - «Теория движения небесных тел»

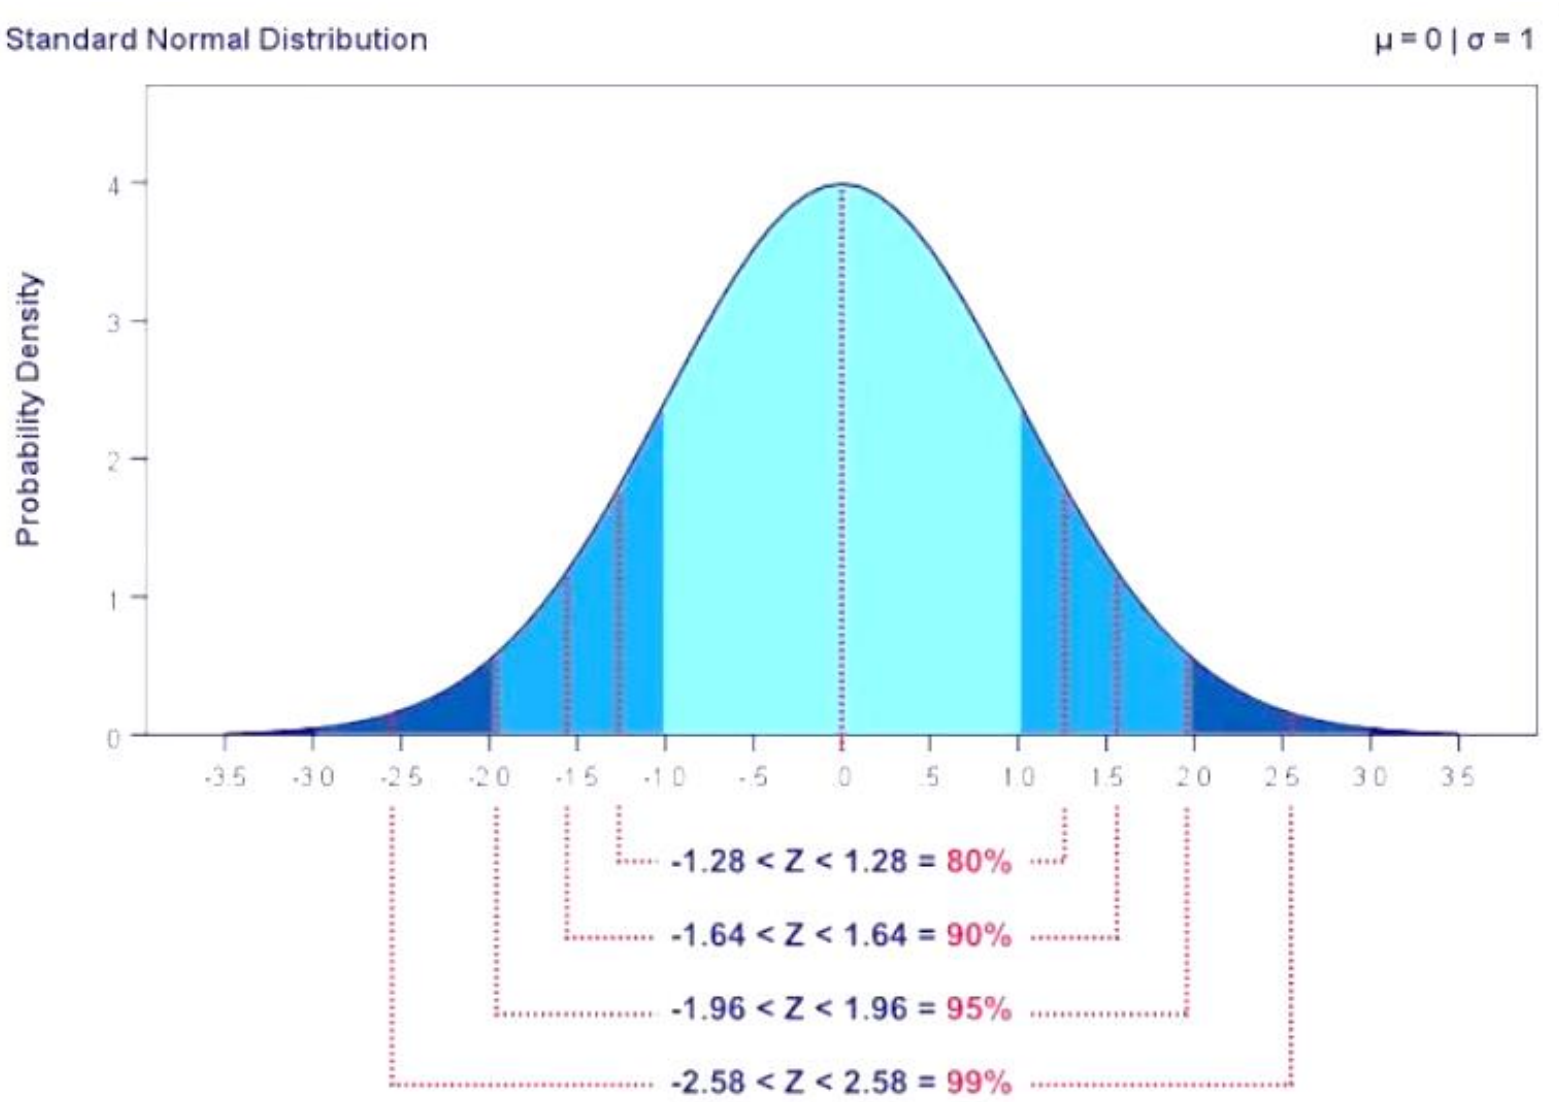
1812г Лаплас - теорема Муавра-Лапласа

Стандартизация



$$X \sim \mathcal{N}\left(\mu, \sigma^2\right) \implies \left(\frac{X-\mu}{\sigma}\right) \sim \mathcal{N}\left(0, 1\right)$$

Квантили


Standard Normal Distribution
μ = 0 | σ = 1
Probability Density
0
1
2
3
4
-3.5
-3.0
-2.5
-2.0
-1.5
-1.0
-.5
0
.5
1.0
1.5
2.0
2.5
3.0
3.5
-1.28 < Z < 1.28 = 80%
-1.64 < Z < 1.64 = 90%
-1.96 < Z < 1.96 = 95%
-2.58 < Z < 2.58 = 99%

t-Distribution

Уильям Госсет





Распределение Стьюдента

Уильям Госсет занимался статистическими исследованиями в компании Guinness для улучшения качества пива, и выведения самого урожайного сорта ячменя.

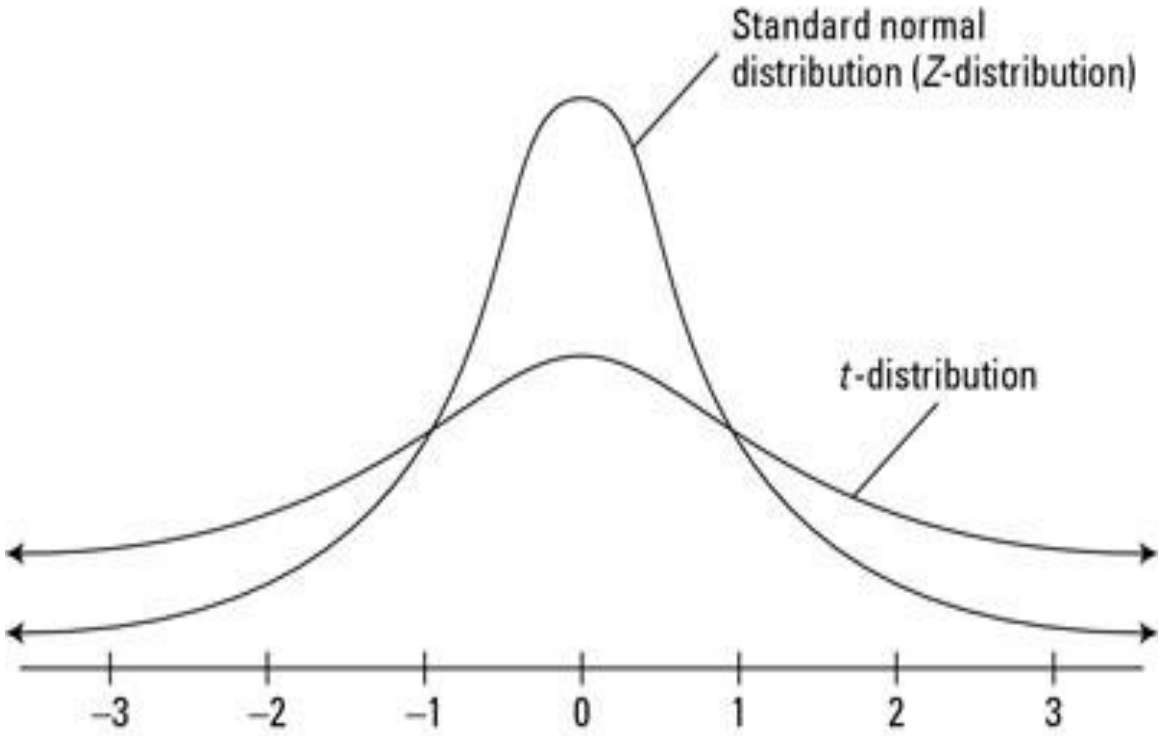
Исследования проводились на малом количестве наблюдений, что послужило толчком для развития методов, работающих на малых выборках.

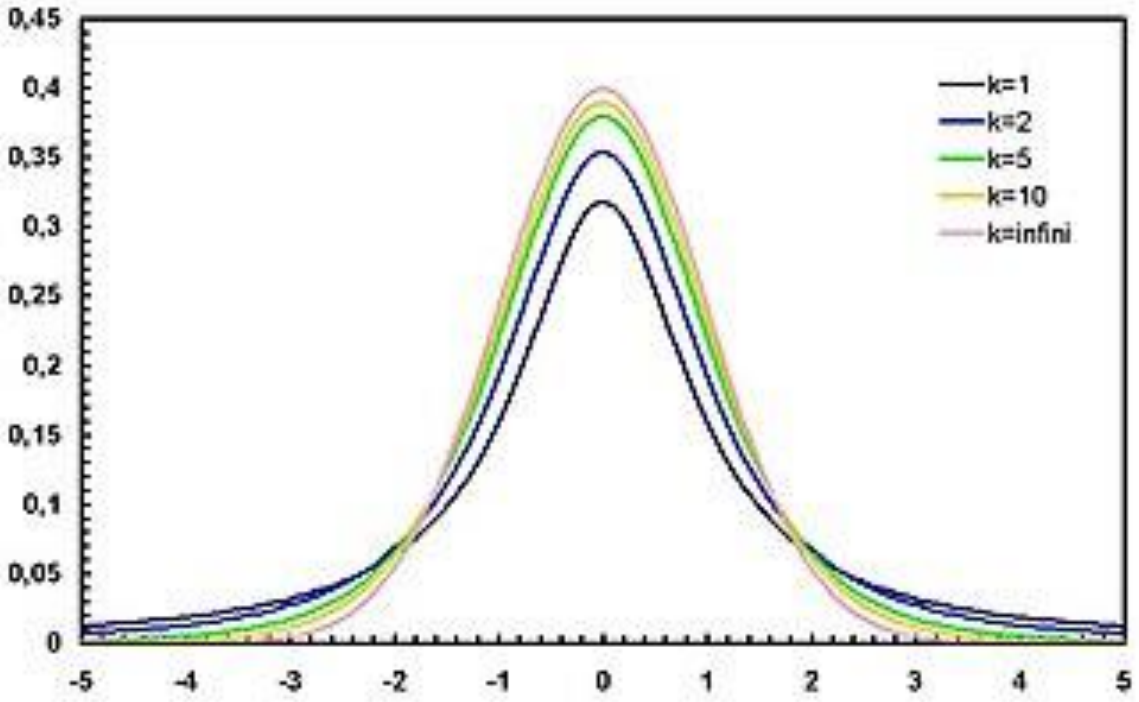
В связи с обязательствами перед компанией по неразглашению коммерческой тайны, статья Госсета вышла в 1908 году под псевдонимом «Student»



$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

t- and z- Distribution



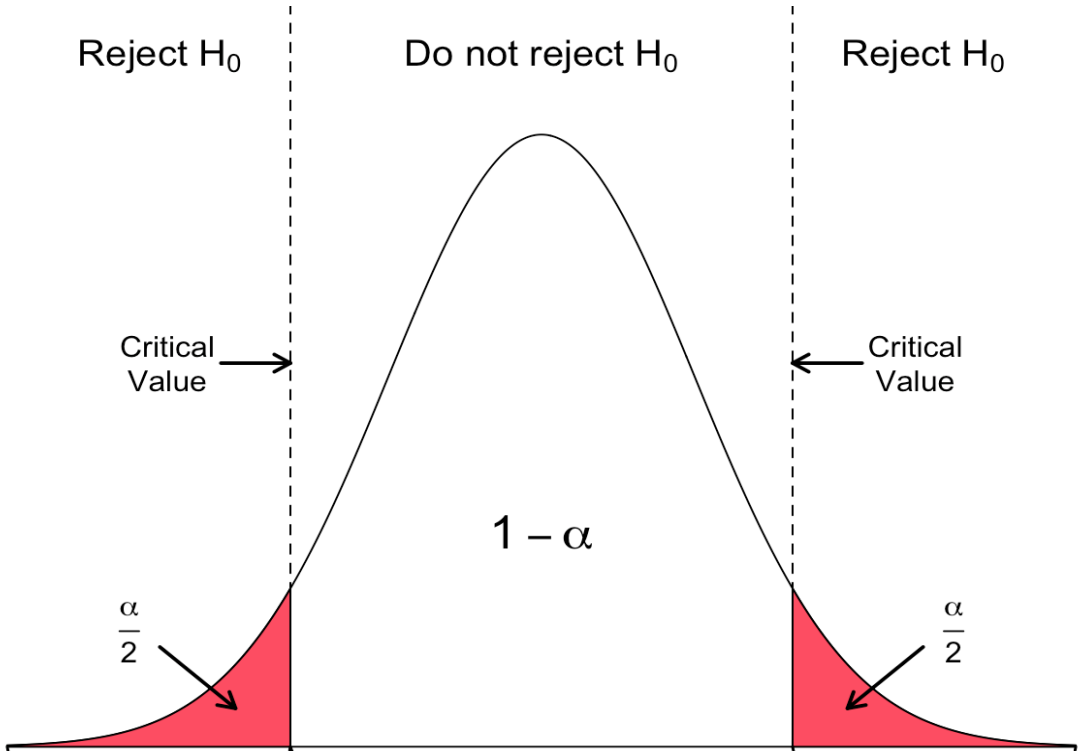


t-test
p-value

H_0 всегда про равенство

$$H_0 : \mu = \mu_0$$
$$H_1 : \mu \neq \mu_0$$

$$t = \frac{\bar{X} - \mu_0}{\hat{\sigma}} \sqrt{n}$$

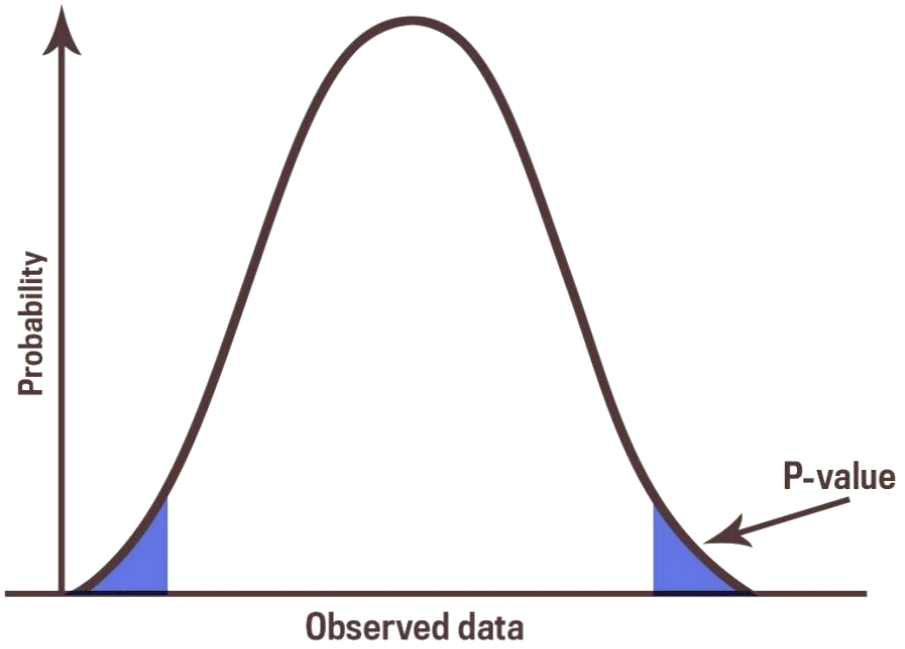


	Медицина	Маркетинг	Экономика
H_0 (эффекта нет)	Новый препарат не эффективнее плацебо.	Изменение цвета кнопки не влияет на конверсию.	Курс доллара не зависит от ключевой ставки.
H_1 (эффект есть)	Препарат работает лучше плацебо.	Красная кнопка увеличивает число покупок.	Рост ставки приводит к укреплению рубля.

If p is low, the null must go!

P-value — вероятность получить эти или более «странные» результаты при условии, что нулевая гипотеза верна.

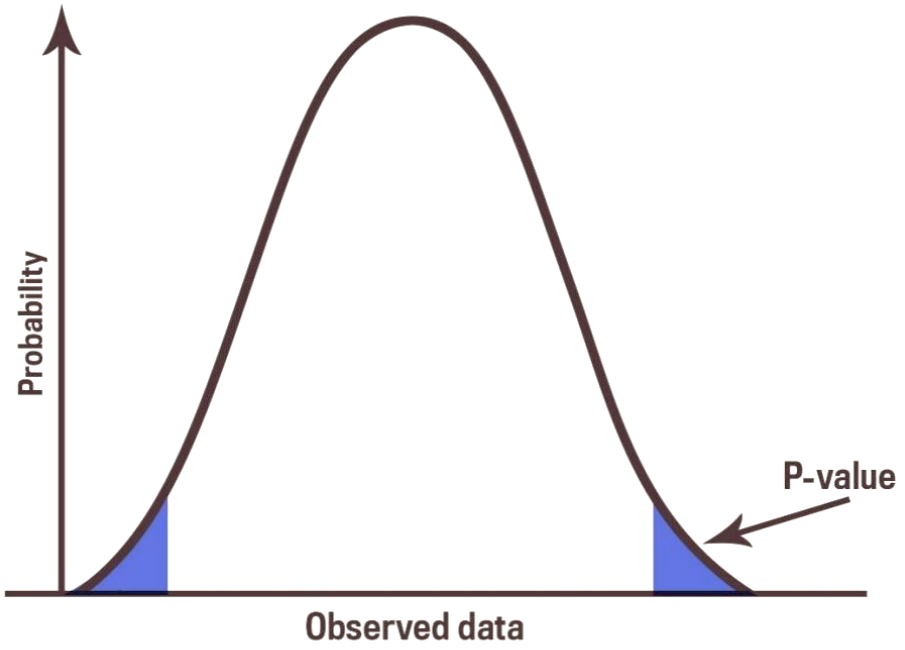
P-value отвечает на вопрос:
«Если на самом деле никаких отличий нет (H0 верна), то каков шанс увидеть полученный результат или еще более «странный» чисто случайно?»



Уровень значимости

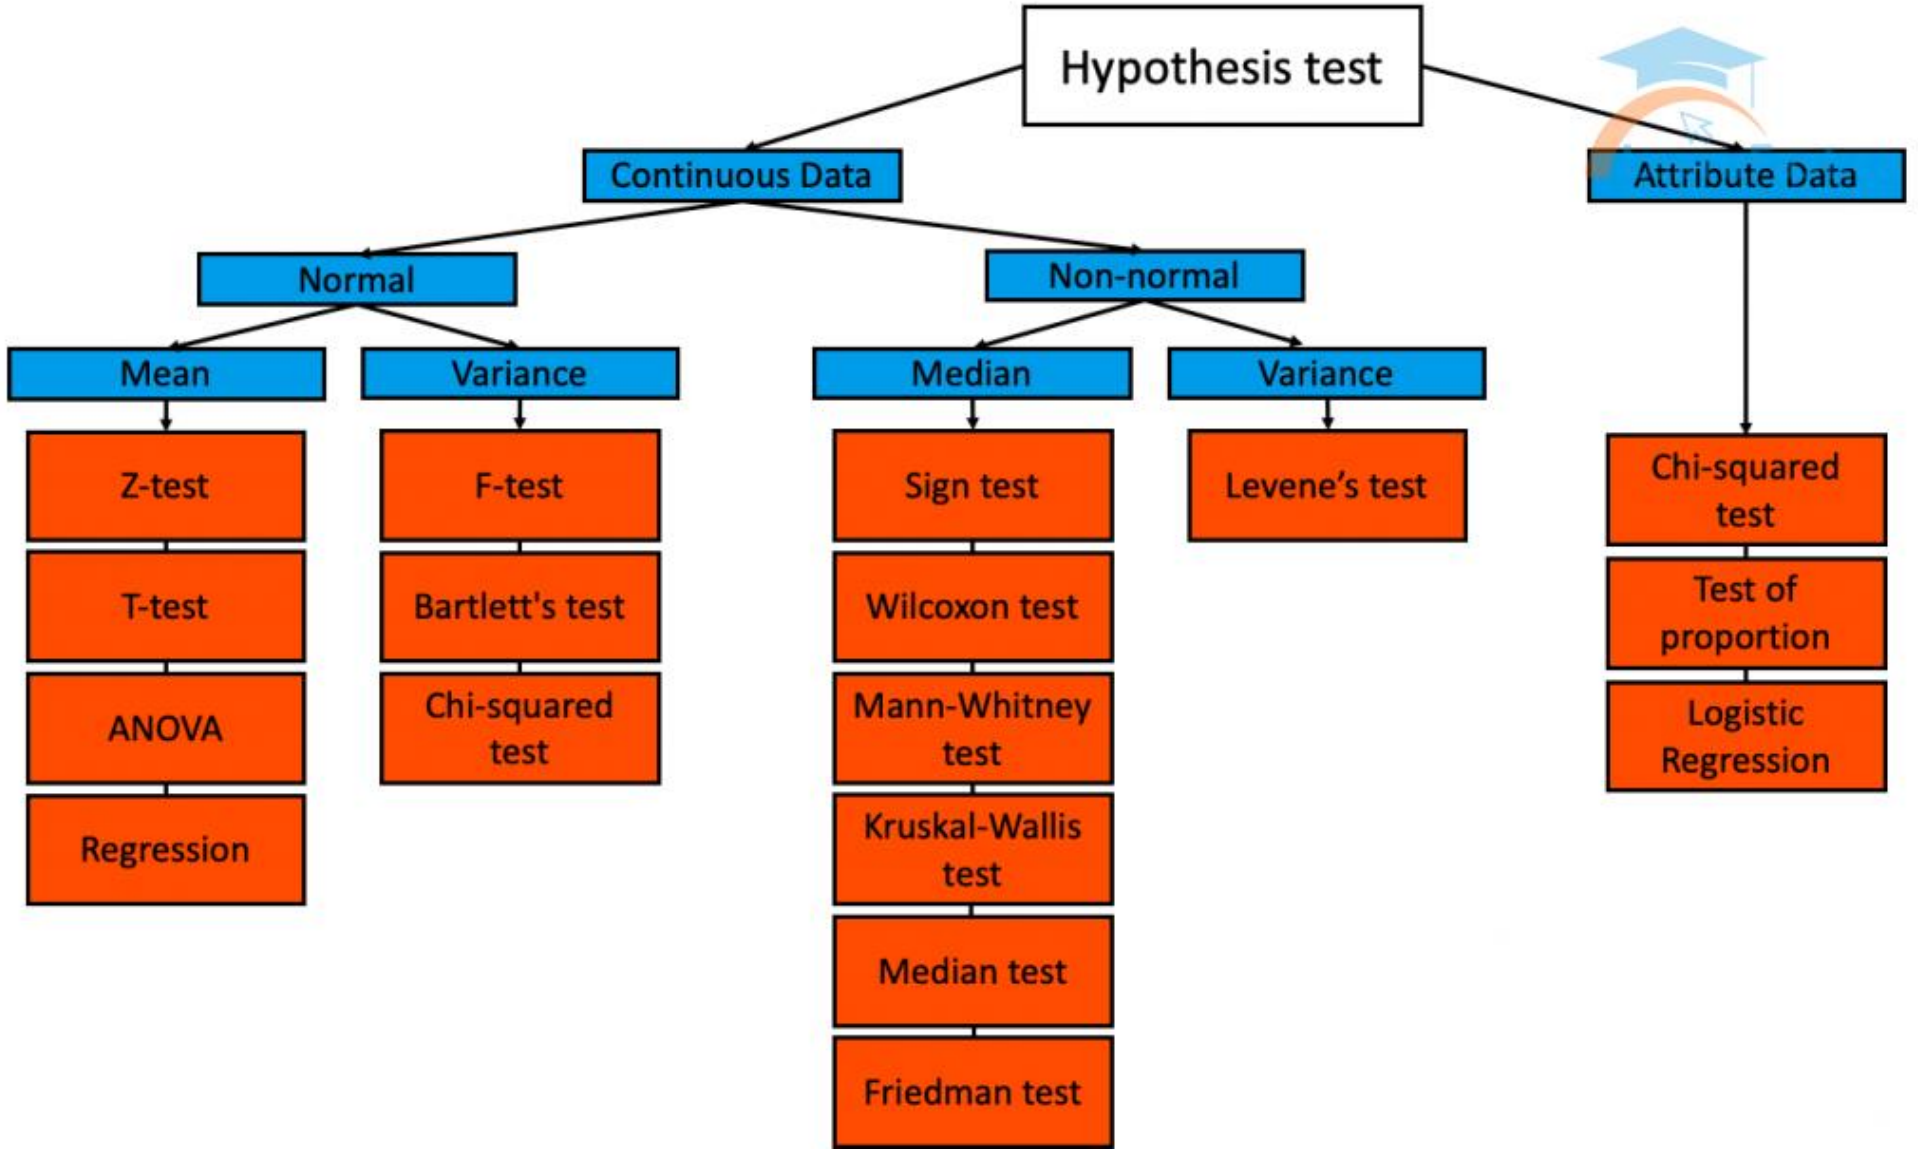
Низкое p-value (обычно < 5%):
«Ух ты! Шанс получить такой результат случайно очень мал!»
Значит наши данные очень сильно противоречат нулевой гипотезе, отвергаем ее

Высокое p-value (обычно > 5%):
«Хм, похоже это просто совпадение»
У нас нет оснований, чтобы отвергнуть нулевую гипотезу, принимаем ее

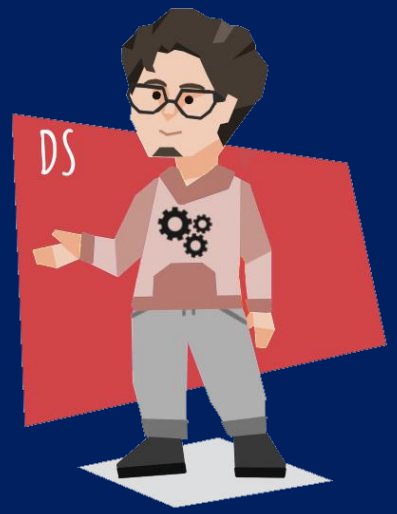


* Другие типы нулевых гипотез

В жизни почти не применяются



Ошибки 1 и 2 рода
TP, TN, FP, FN





Ошибки

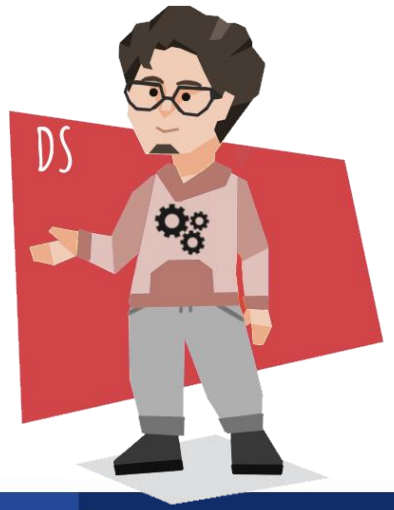
- Ошибка 1 рода происходит, когда мы отвергаем нулевую гипотезу (принимаем альтернативную), когда она правильная
- Ошибка 2 рода происходит, когда мы не отвергаем нулевую гипотезу, когда альтернативная гипотеза правильная

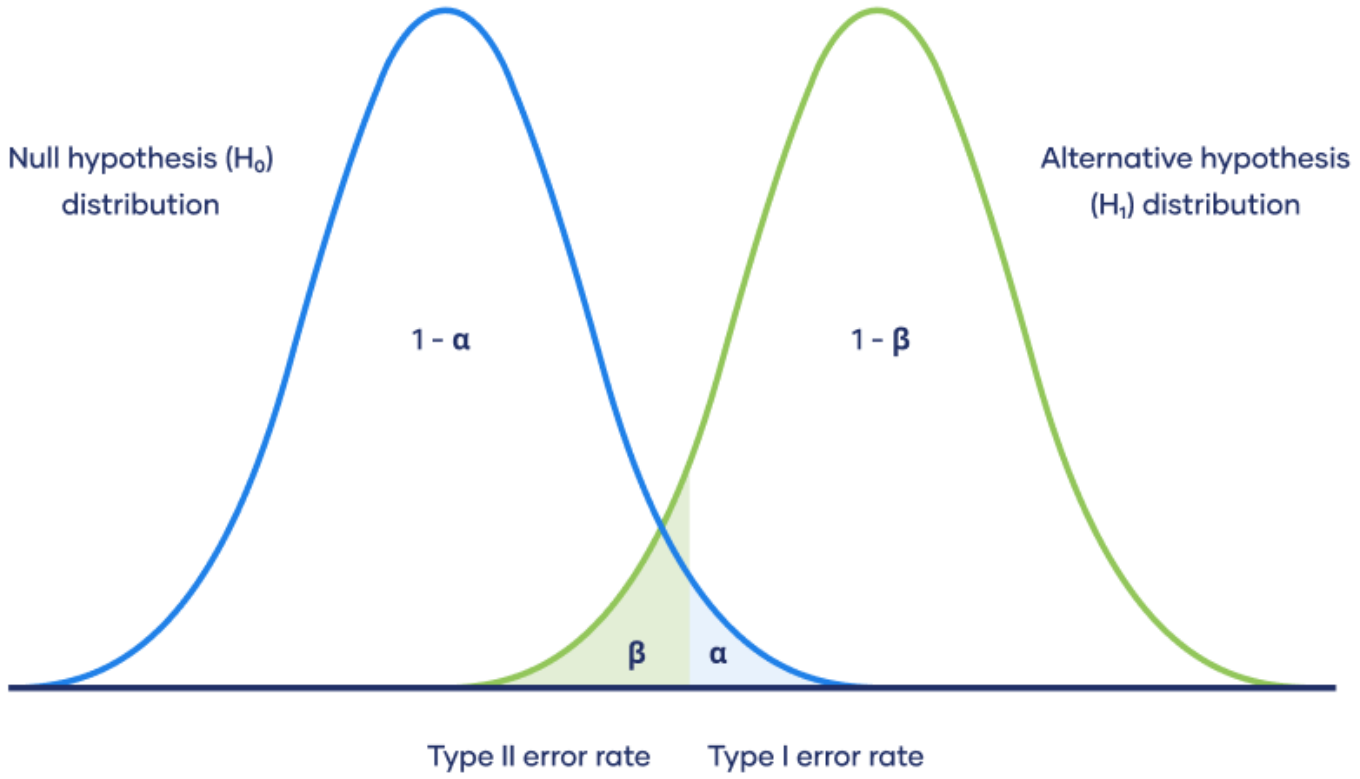
		Верная гипотеза	
		H_0	H_1
Результат применения критерия	H_0	H_0 верно принята	H_0 неверно принята (Ошибка *второго* рода)
	H_1	H_0 неверно отвергнута (Ошибка *первого* рода)	H_0 верно отвергнута

Alpha, Beta

Alpha = **P(Ош.1 Рода)** = P(H1|H0) =
= уровень значимости

Beta = **P(Ош.2 Рода)** = P(H0|H1)
1-Beta = P(H1|H1) = мощность

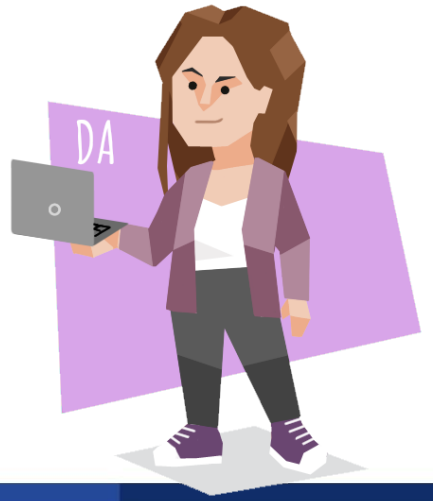


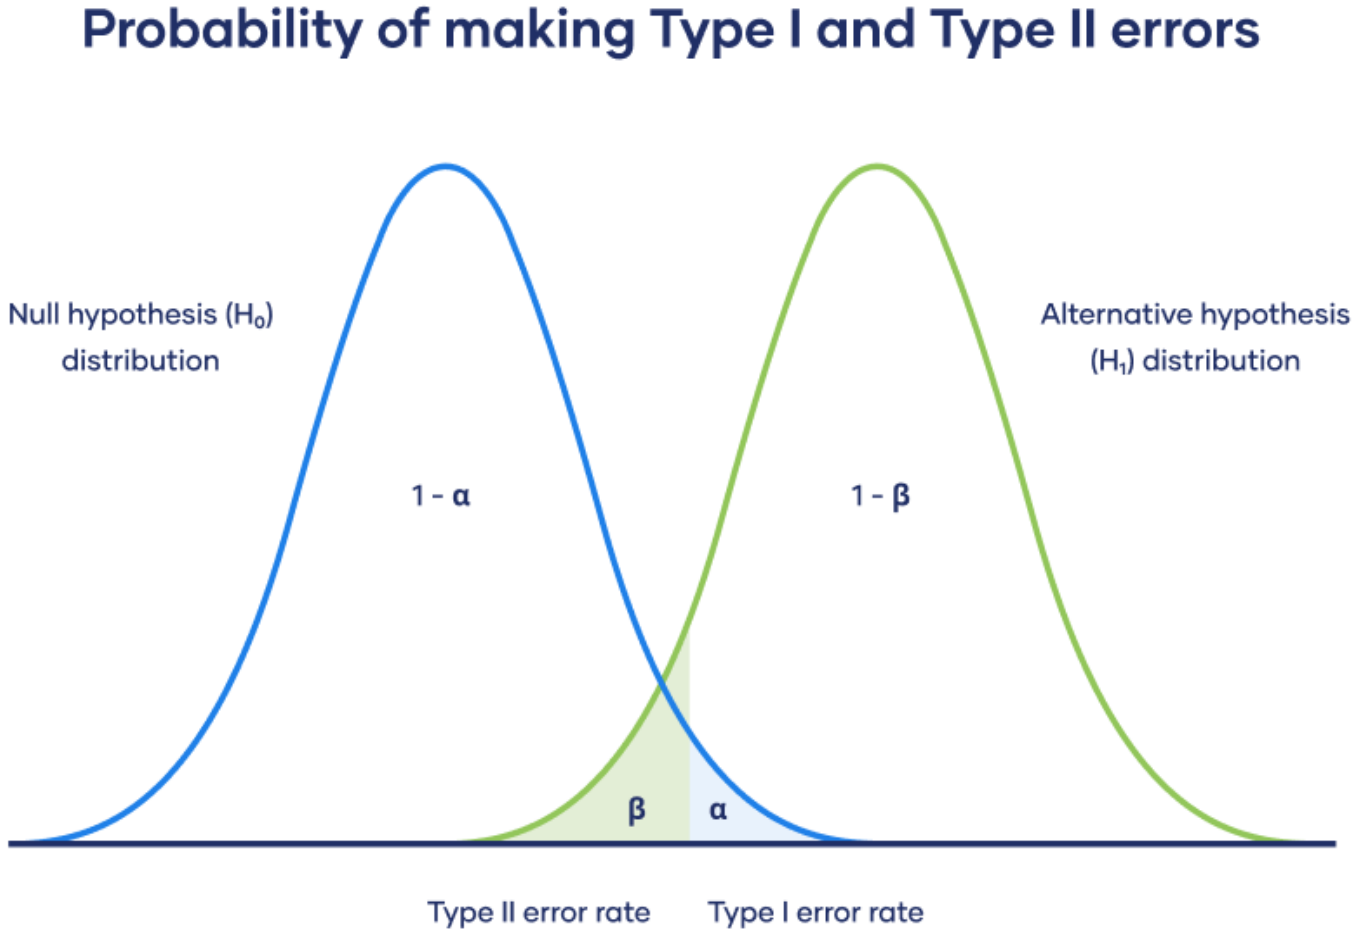


Alpha, Beta интерпретация

P(Ош.1 Рода) = P(H1|H0) = 0
Мы ни разу не врали начальству, что значимый эффект был, когда его не было

P(Ош.2 Рода) = P(H0|H1) = 0
Мы заметили все значимые эффекты, никого не пропустили



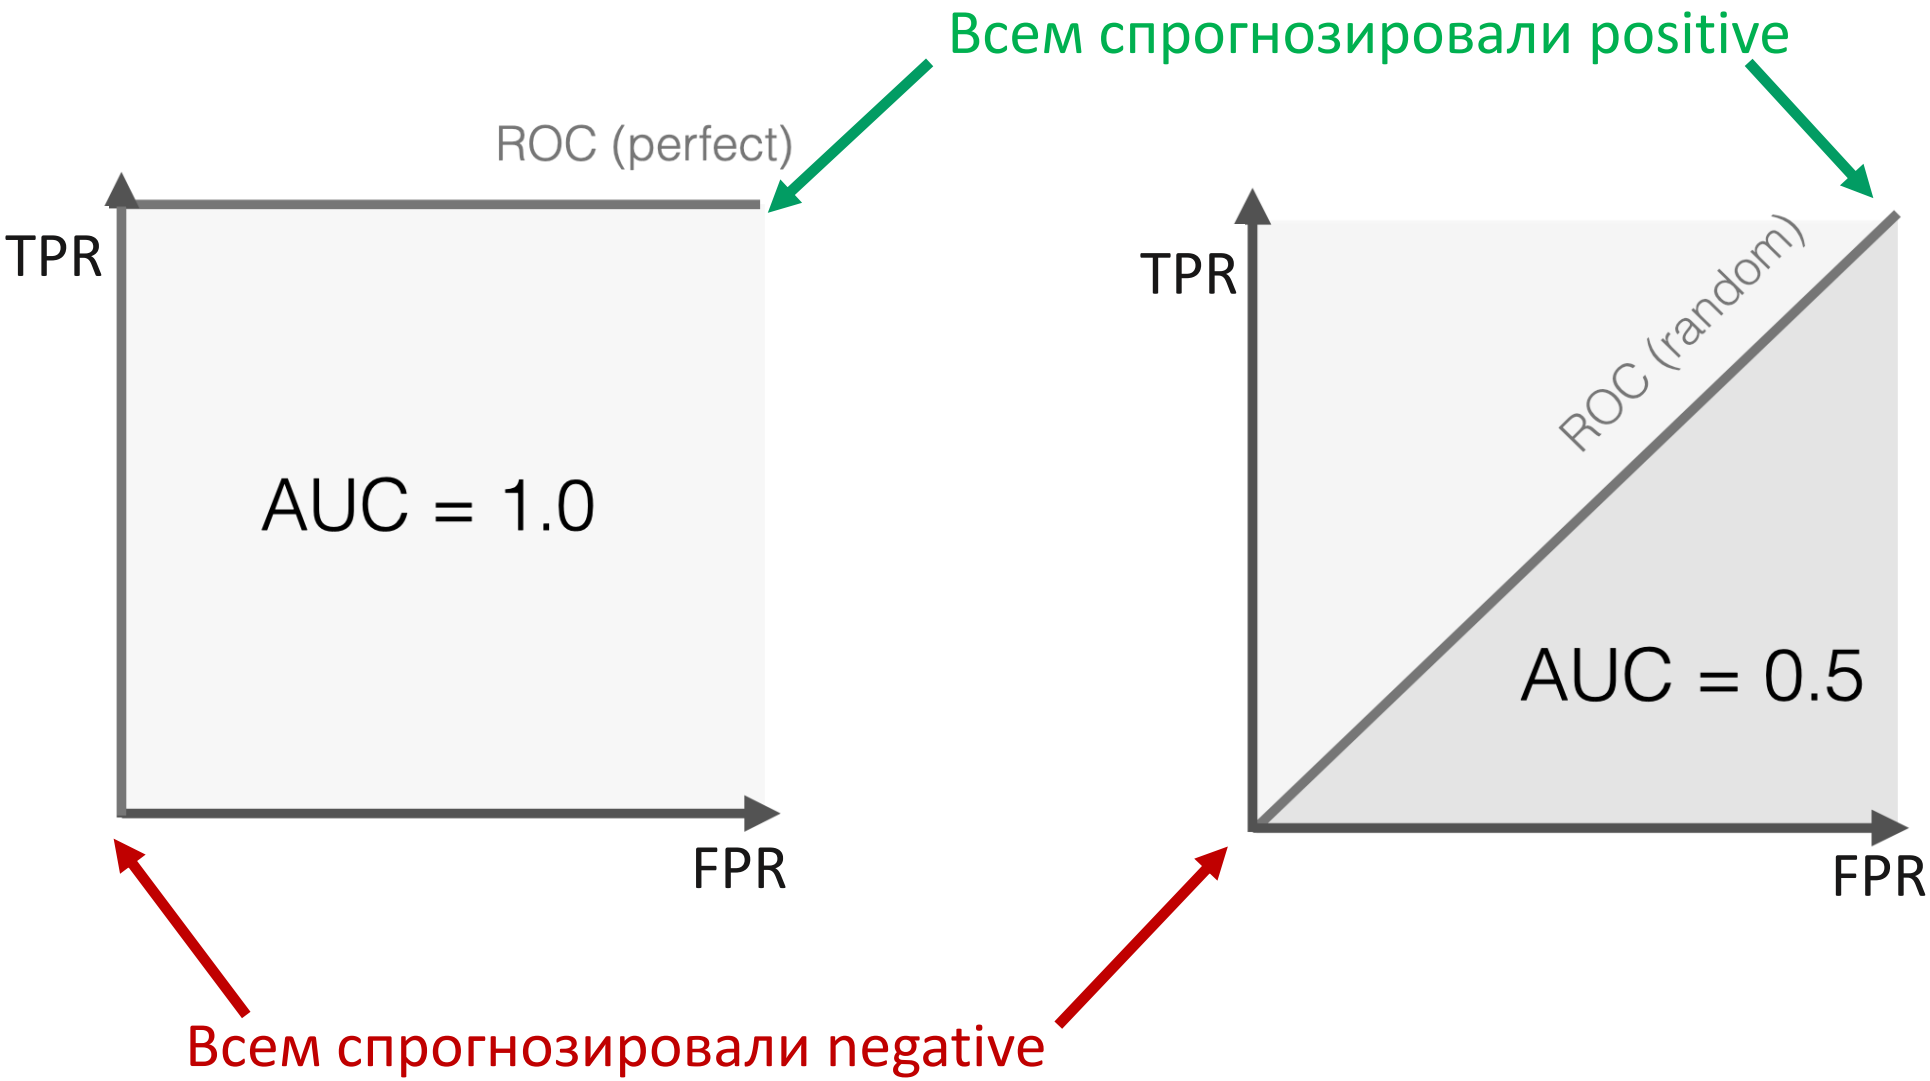


Confusion Matrix

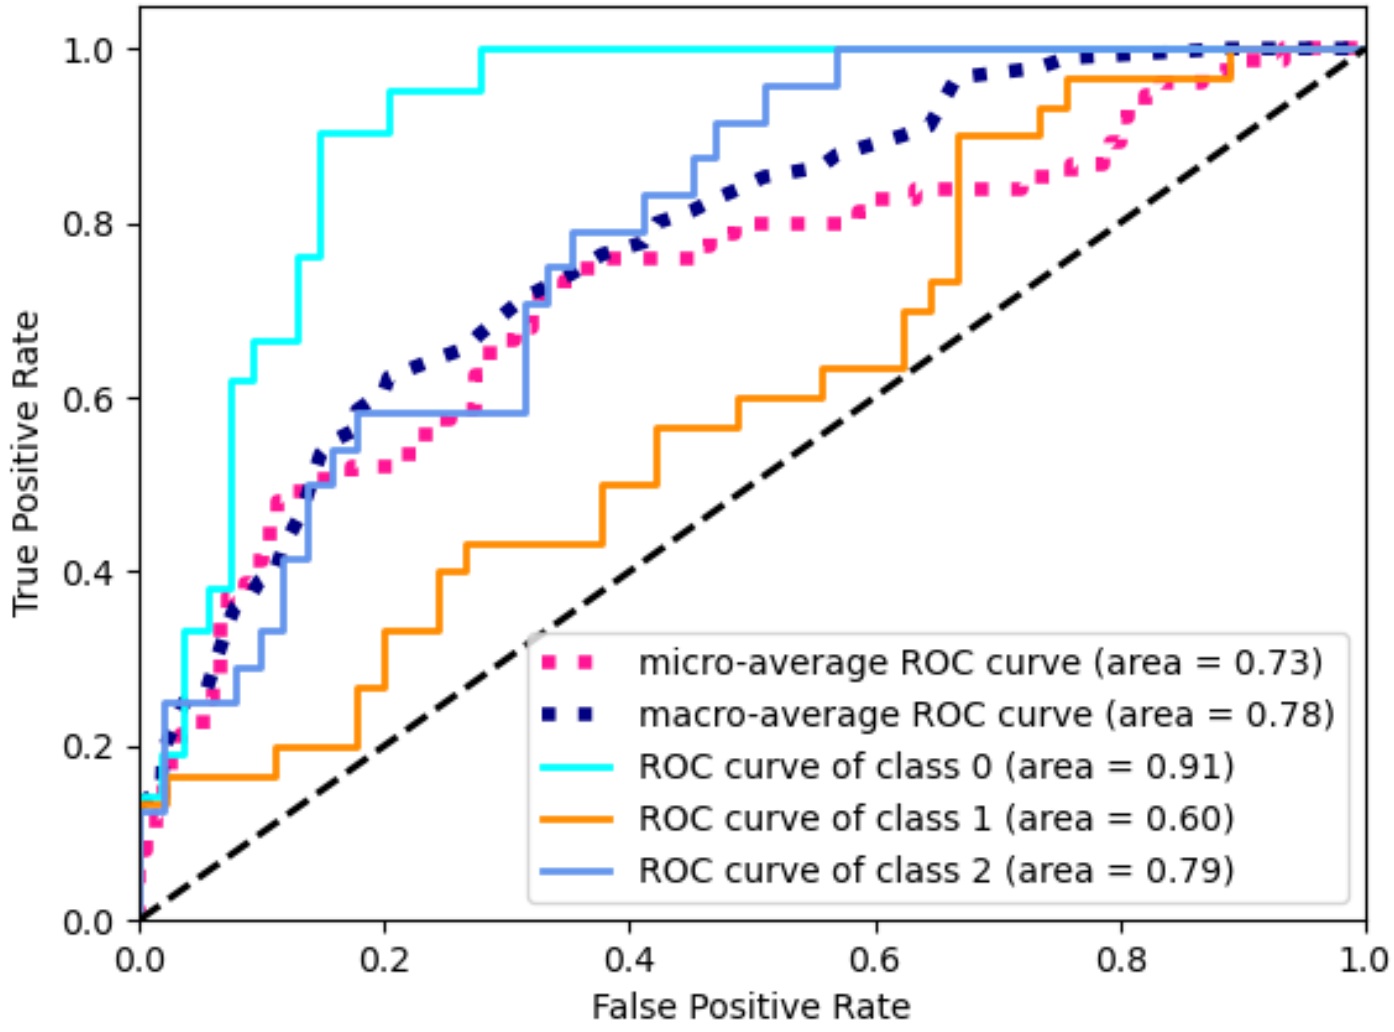
Actual Class \ Predicted Class	Positive	Negative	
Positive	True Positive (TP)	False Negative (FN) **Type II Error**	**Sensitivity** $\frac{TP}{(TP+FN)}$ = TPR
Negative	False Positive (FP) **Type I Error**	True Negative (TN)	**Specificity** $\frac{TN}{(TN+FP)}$ = 1- FPR
	Precision $\frac{TP}{(TP+FP)}$	**Negative Predictive Value** $\frac{TN}{(TN+FN)}$	**Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$

ROC AUC

Крайние случаи



Для сравнения моделей



Литература
реально полезная

Литература по 6 лекции

- p-value
- ошибки 1 и 2 рода

Любые вопросы!



Спасибо за внимание!